

Πανεπιστήμιο Ιωαννίνων

Τμήμα Μηχανικών Η/Υ και Πληροφορικής



ΜΥΕ012 Εξόρυξη Δεδομένων

Φοιτητής:

Χρήστος Γούλας

2677

Ερώτηση 1η:

Ψευδοκώδικας:

K = δείγμα σταθερού μεγέθους

N = μέγεθος ροής

- Αποθήκευση των πρώτων k στοιχείων της Ροής στο K.
(Έστω ότι έχουμε ήδη διαχειριστή n – 1 στοιχεία της ΡΟΗΣ. Το δείγμα μας (K) περιλαμβάνει ακριβώς K από αυτά **τυχαία και ισοπίθανα με πιθανότητα $1/(n - 1)$**).
- Κατά την εμφάνιση του n-οστού στοιχείου (n > K) της Ροής.
 - Με πιθανότητα K/n επιλέγουμε το n-οστό στοιχείο να προστεθεί στο δείγμα K, αλλιώς το απορρίπτουμε.
 - **ΑΝ** το n-οστό στοιχείο επιλέχθηκε για προσθήκη στο K.
- **TOTE** το n-οστό στοιχείο αντικαθιστά ένα από τα k στοιχεία που είναι ήδη μέσα στο δείγμα K. Αυτό που θα αντικατασταθεί επιλέγεται τυχαία και ισοπίθανα.

A1)

Λογική:

Ουσιαστικά υπολογίζουμε κάθε φορά την πιθανότητα να βρίσκεται ένα στοιχείο μέσα στο δείγμα μας (στον κώδικα αυτή η πιθανότητα είναι η $p_1 = K / N$) και στη συνέχεια χρησιμοποιούμε άλλη μία πιθανότητα που παίρνουμε τυχαία η οποία “αντιστοιχεί” στην πιθανότητα του n-οστού στοιχείου της ροής που μόλις εμφανίστηκε (στον κώδικα αυτή είναι η πιθανότητα p_2). Συγκρίνοντας αυτές τις δύο βάζουμε στο δείγμα μας το στοιχείο που μας εμφανίστηκε μόνο αν η $p_2 \leq p_1$. Ουσιαστικά με αυτό τον έλεγχο διαφυλάσσουμε ότι οποιοδήποτε στοιχείο εμφανίζεται στο δείγμα μας θα έχει πιθανότητα μικρότερη ίση του K / N . Το οποίο είναι και το ζητούμενο ώστε το δείγμα μας να είναι αντιπροσωπευτικό (ομοιόμορφα τυχαίο δείγμα).

A2) **Απόδειξη με μαθηματική επαγωγή:**

Βάση : Για $N \leq K$ στοιχεία μέχρι στιγμής το δείγμα K έχει τη ζητούμενη ιδιότητα:

Κάθε στοιχείο της ροής περιλαμβάνεται στο δείγμα με πιθανότητα: $n / n = 1$.

Υπόθεση : Έστω ότι μετά από την εμφάνιση $n \geq k$ στοιχείων, το δείγμα K περιλαμβάνει κάθε στοιχείο που έχει εμφανιστεί μέχρι στιγμής με πιθανότητα: k/n

Βήμα : Θα δείξω ότι και μετά την εμφάνιση του $(n + 1)$ στού στοιχείου της ροής , το δείγμα K περιλαμβάνει καθένα από τα $n + 1$ πρώτα στοιχεία της ροής με πιθανότητα:

$$k/(n + 1)$$

Υπόθεση : Έστω ότι μετά από την εμφάνιση $n \geq k$ στοιχείων, το δείγμα K περιλαμβάνει κάθε στοιχείο που έχει εμφανιστεί μέχρι στιγμής με πιθανότητα: k / n

Βήμα :

- Το $(n + 1)$ στό στοιχείο της ροής, ήδη έχει πιθανότητα επιλογής για δείγμα K ακριβώς: $k / (n + 1)$
- Δεδομένα ότι ήταν μέσα στο K , η πιθανότητα ενός από τα πρώτα n στοιχεία (έστω x) να παραμείνει εντός του K τη στιγμή $n+1$ είναι:

$$(1 - k/(n+1)) + (k/(n + 1)) * ((k - 1)/k) = 1 - k/(n+1) + (k - 1)/(n + 1) = n/(n + 1)$$

Όπου:

- $(1 - k/(n+1)) = \text{"Δεν επιλέγεται το } n + 1\text{"}$.
- $k/(n + 1) = \text{"Επιλέγεται το } n + 1\text{"}$.
- $(k - 1)/k = \text{"Δεν επιλέγεται για απόρριψη το } x\text{"}$.

Η συνολική πιθανότητα ενός από τα πρώτα n στοιχεία να βρίσκεται εντός του δείγματος K τη χρονική στιγμή $n + 1$ είναι:

$$(k/n) * (n/(n + 1)) = k/(n + 1)$$

A3) Σας επισυνάπτω τον κώδικα στο αρχείο με όνομα ReservoirSampling.py .

Παρατηρήσεις: Αντιμετώπισα κάποια προβλήματα με το powershell και το "<" οπότε για να τρέξει το πρόγραμμα αυτό που κάνουμε είναι:

```
python ReservoirSampling.py 10 input.txt
```

B) Ουσιαστικά μπορούμε να χρησιμοποιήσουμε ακριβώς τον ίδιο αλγόριθμο αλλά αυτή τη φορά το δείγμα μας έχει μέγεθος $K=1$. Αυτό συμβαίνει γιατί στο δέντρο που θα μας δοθεί θέλουμε να δειγματοληπτούμε μόνο ένα κόμβο.

Ερώτηση 2η:

Τα $x_1, x_2, \dots, x_n$ είναι σε αύξουσα σειρά. Άρα σχηματικά θα είναι:



Τώρα για $z = X_{k+1}$:

$$\sum_{i=1}^n |X_i - X_{k+1}| = |X_1 - X_{k+1}| + \dots + |X_{k+1} - X_{k+1}| + \dots + |X_n - X_{k+1}|$$

A

- Έστω τώρα $\epsilon > 0$ με $\epsilon \leq X_{k+2} - X_{k+1}$. Άρα $X_{k+1} + \epsilon \leq X_{k+2}$.

Οπότε:

Για $z = X_{k+1} + \varepsilon$, δηλαδή z ανήκει $(X_{k+1}, X_{k+2}]$ έχουμε στο άθροισμα:

$$\begin{aligned} \sum_{i=1}^n |X_i - X_{k+1} - \varepsilon| &= |X_1 - X_{k+1} - \varepsilon| + \dots + |X_{k+1} - X_{k+1} - \varepsilon| + \dots + |X_n - X_{k+1} - \varepsilon| \\ &= X_{k+1} + \varepsilon - X_1 + \dots + \varepsilon + X_{k+2} - X_{k+1} - \varepsilon + \dots + X_n - X_{k+1} - \varepsilon = \\ &= X_{k+1} - X_1 + \dots + \varepsilon + X_{k+2} - X_{k+1} + X_n - X_{k+1} = A + \varepsilon \end{aligned}$$

Άρα για z ανήκει στο $(X_{k+1}, X_{k+2}]$ έχουμε :

$$\sum_{i=1}^n |X_i - z| = A + \varepsilon > A$$

Παρόμοια για z ανήκει στο $(X_{k+m}, X_{k+m+1}]$ με $m > 1$ έχουμε :

$$\begin{aligned} \sum_{i=1}^n |X_i - z| &= |X_1 - X_{k+1} - \varepsilon| + \dots + |\varepsilon| + \dots + |X_{k+m+1} - X_{k+1} - \varepsilon| + \dots + |X_n - X_{k+1} - \varepsilon| = \\ &= (X_{k+1} + \varepsilon - X_1) + \dots + \varepsilon + (\varepsilon - X_{k+2} + X_{k+1}) + \dots + (\varepsilon - X_{k+m} + X_{k+1}) + (-\varepsilon + X_{k+m+1} - X_{k+1}) \\ &+ (X_n - X_{k+1} - \varepsilon) = \\ &= A + (k+m) \cdot \varepsilon - (2k+1 - k - m - 1 + 1) \cdot \varepsilon = A + \varepsilon (k+m - k - m - 1) = A + \varepsilon (-2) > A \end{aligned}$$

Παρόμοια αν $z > X_n$.

Τώρα για $z < X_{k+1}$ (εξετάζουμε απευθείας την γενική περίπτωση), δηλαδή για $z = X_{k+1} - \varepsilon$ και z ανήκει $[X_{k-m-1}, X_{k-m})$ έχουμε:

$$\begin{aligned} \sum_{i=1}^n |X_i - X_{k+1} + \varepsilon| &= |X_1 - X_{k+1} + \varepsilon| + \dots + |X_{k-m-1} - X_{k+1} + \varepsilon| + |X_{k-m} - X_{k+1} + \varepsilon| + \dots + |\varepsilon| + \dots \\ &+ |X_n - X_{k+1} + \varepsilon| = (X_{k+1} - X_1 - \varepsilon) + \dots + (X_{k+1} - \varepsilon - X_{k-m-1}) + (X_{k-m} - X_{k+1} + \varepsilon) + \dots + \varepsilon + \dots + \\ &+ (X_n - X_{k+1} + \varepsilon) = \\ &= A - \varepsilon (k-m-1) + \varepsilon (n - k + m + 1) = A - \varepsilon (k-m-1 - k-m-2) = A - \varepsilon (-2m-3) > A \end{aligned}$$

Παρόμοια για $z < X_1$

Τελικά παρατηρούμε ότι για $z = X_{k+1}$ παίρνουμε το ελάχιστο.

Ερώτηση 3η:

Πρώτη εκδοχή :

$$\text{Sim}(X,Y) = \cos(r_x,r_y)= 0.936974961$$

$$\text{Sim}(X,Z) = \cos(r_x,r_z)= 0.511101252$$

$$\text{Sim}(X,W) = \cos(r_x,r_w)= 0.566946709$$

Σύμφωνα με τα παραπάνω πιο όμοιοι χρήστες φαίνονται οι Y και W.

$$Z = 1.50392167$$

Βαθμολογία για κελί (X,6): 2.130936644

Δεύτερη εκδοχή :

Ο πίνακας διαμορφώνεται ως εξής :

Users	Movie 1	Movie 2	Movie 3	Movie 4	Movie 5	Movie 6
X	2	0		- 2		?
Y	2	0	- 1			- 1
Z	$\frac{1}{2}$			- $\frac{3}{2}$	$\frac{1}{2}$	$\frac{1}{2}$
W	- $\frac{4}{3}$	$\frac{5}{3}$	- $\frac{7}{3}$	$\frac{5}{3}$	- $\frac{1}{3}$	$\frac{2}{3}$

$$\text{Sim}(X,Y) = \cos(r_x,r_y)= 0.5773502629$$

$$\text{Sim}(X,Z) = \cos(r_x,r_z)= 0.81649658$$

$$\text{Sim}(X,W) = \cos(r_x,r_w)= - 0.580947501$$

Σύμφωνα με τα παραπάνω πιο όμοιοι χρήστες φαίνονται οι Y και Z.

$$Z = 1.50392167$$

Απόκλιση: - 0.1232034

Παρατηρήσεις :

α) Ποια κελιά έχουν μικρότερη ή μεγαλύτερη σημασία στον υπολογισμό της ομοιότητας σε κάθε εκδοχή;

Απάντηση :

Εκδοχή Α : Τα κελιά που έχουν μεγαλύτερη σημασία στον υπολογισμό είναι τα $(Y,1)$, $(Y,2)$, $(W,1)$, $(W,2)$, $(W,4)$.

Εκδοχή Β : Τα κελιά που έχουν μεγαλύτερη σημασία στον υπολογισμό είναι τα $(Y,1)$, $(Z,1)$, $(Z,4)$.

Παρατήρηση : Ουσιαστικά μεγαλύτερη σημασία έχουν τα κελιά τα οποία συντελούν στο γινόμενο του αριθμητή του τύπου της ομοιότητας συνημιτόνου, δηλαδή όσα δεν είναι μηδενικά στην ίδια θέση και στα 2 διανύσματα. Τα κενά κελιά θεωρούμε πως έχουν 0. Ενώ μικρότερη σημασία έχουν τα κελιά τα οποία είναι μη μηδενικά (κενά) σε ένα από τα δύο διανύσματα αλλά όχι στην ίδια θέση στα δύο διανύσματα.

β) Πώς αλλάζουν οι πιο κοντινοί γείτονες;

Απάντηση :

Εκδοχή Α : Οι πιο κοντινοί γείτονες είναι οι Y και W.

Εκδοχή Β : Οι πιο κοντινοί γείτονες είναι οι Y και Z.

Παρατήρηση : Οι πιο κοντινοί γείτονες άλλαξαν λόγο της διαφορετικής υλοποίησης. Ουσιαστικά στη δεύτερη περίπτωση που αφαιρούμε τη μέση τιμή αυτό που κάνουμε μας αναδεικνύει τη “βαρύτητα” των ψήφων του κάθε χρήστη. Πιο συγκεκριμένα μέσω της αφαίρεσης της μέση τιμής βλέπουμε μια αντιστοιχία ανάμεσα στο πως βαθμολογεί γενικά ο κάθε χρήστης και πως βαθμολόγησε μια ταινία. Έτσι κατ’ επέκταση παίρνουμε πιο ακριβή ‘βαρύτητα’ για κάθε βαθμό.

Για παράδειγμα: Αν δύο χρήστες έχουν βαθμολογήσει μία ίδια ταινία με 1 ενώ στις υπόλοιπες ταινίες ο ένας βάζει τιμές πολύ κοντά στο 5 ενώ ο άλλος κοντά στο 3 η βαρύτητα του 1 δεν είναι ίδια για τους 2 χρήστες.

Γι’ αυτό και αναδεικνύεται αυτή η διαφορά στους κοντινούς γείτονες στην άσκηση ανάμεσα στις 2 εκδοχές.

γ) Τι βαθμολογία υπολογίζετε σε κάθε περίπτωση;

Απάντηση :

Εκδοχή Α : Βαθμολογία για κελί (X,6): 2.130936644

Εκδοχή Β : Βαθμολογία για κελί (X,6): 2.87867966